



# 基於 WGAN-GP 的字體風格遷移研究

## 一、研究動機

近年出現多個英文字體生成工具。然而由於漢字結構複雜、字數龐大等特性，少見生成中文字體的應用。因此本研究決定嘗試在少樣本的前提下，製作能夠生成字數整日清晰的中文字體之工具。研究初期以英文作為實驗對象，最終將經驗整合應用於中文字體，以降低個人化中文字體的製作門檻。

## 二、研究目的

1. 建構基於 WGAN-GP 的字體生成模型
2. 探討資料增強技術對泛化能力以及生成效果之影響
3. 分析生成器瓶頸層 (Bottleneck) 尺寸對生成效果之影響
4. 最佳化損失函數權重配置
5. 評估跨語言字體生成之可行性

# 貳、文獻探討

## 一、GAN 用於圖片生成的潛力及其演進


GAN 透過生成器與判別器互相訓練，可生成接近真實樣本的輸出。DCGAN 的出現證明了此架構於圖片生成評估的潛力。原始 GAN 基於 JS 散度評估，易出現訓練不穩定或模式崩潰等問題。因此 WGAN 改使用了 Wasserstein 距離改善前述之缺陷。而後 WGAN-GP 進一步以梯度懲罰取代權重裁剪，大幅提升其穩定性，故本研究選擇其作為基礎架構。[1][2][3][4]

## 二、字體生成方面相關研究

本研究借鑒 Pix2pix 的編解碼器架構及雙損失函數 (L1 損失與對抗損失) 配置，不過為了聚焦在 WGAN-GP 架構的研究，故不採用前者使用的 U-Net 架構。與 zi2zi 的方法不同，本研究將字體生成視為一對一風格轉換，不使用預訓練資料。最終從 Wen 等人的研究中獲得同步變換增強的參考，並嘗試加入了旋轉及遮罩操作。[5][6][7][8]

# 參、研究方法及過程

## 一、研究流程




## 二、生成字體評估標準

1. 量化評分：評估圖片相似的「SSIM」、基於深度學習，反應風格相似的「LPIPS」、評估特徵分佈相似度，為字體生成領域標準的「FID」
2. 結構完整性：字符骨架是否正確、無出現筆畫缺失或錯位等
3. 風格一致性：是否保留目標字體的特徵筆觸、在整體視覺上接近目標字體
4. 清晰度：筆畫邊緣需清晰、無範圍模糊、雜訊或多餘像素點

## 三、模型架構

生成器採用「編碼器-解碼器」架構，結合判別器與 L1 像素損失加權評分。

並於訓練時移除部分字符，模擬資料缺失，後續結果皆為模型於這些未見字符的表現。



## 四、同步變換增強

(一) 幾何變換 (圖 3) [7]:

1. 縮放 (Scaling) :  $(S_{min}, S_{max})$  表縮放的最小和最大比例。
2. 平移 (Translation) :  $(T_x, T_y)$  表圖片在 x, y 軸的最大偏移比例。
3. 旋轉 (Rotation) : 參數  $\theta$  表旋轉範圍  $\pm \theta$  度。

(二) 隨機遮罩 (圖 4) :

以固定機率  $P_{mask}$  對輸入圖像及目標圖像隨機遮蔽同一塊矩形區域。

圖 3：幾何變換示意圖 (左)

圖 4：隨機遮罩示意圖 (右)



## 五、可變的瓶頸層

瓶頸層指編碼器壓縮後的潛空間，本研究將瓶頸層尺寸設為實驗變因，探討  $n \times n$  ( $n=1,2,4,8,16$ ) 的瓶頸層對生成品質的影響。控制變因則固定模型卷積層數，依照「空間解析度隨下採樣減半，特徵通道數 (Channels) 相應翻倍」的邏輯下採樣，直到瓶頸層尺寸達到目標尺寸。在瓶頸層實驗中模型層數固定為 6 層，其他實驗則固定為 5 層。

## 六、損失函數設計

(一) 對抗損失 (adv Loss) :  
即生成圖像被判別器評分為「假」的程度，該值越低越好。

$$\mathcal{L}_{adv} = -\mathbb{E}_{z, I_s} [D(G(z, I_s))]$$

(二) L1 損失 (L1 Loss) :  
生成圖像與真實目標圖像像素值的絕對誤差平均值，作為結構約束。

$$\mathcal{L}_{L1} = \mathbb{E}_{I_s, I_t} [\|G(z, I_s) - I_t\|_1]$$

(三) 總損失函數：  
由權重參數  $\lambda_{L1}$  平衡上述兩項損失值：

$$\mathcal{L}_{Total} = \mathcal{L}_{adv} + \lambda_{L1} \cdot \mathcal{L}_{L1}$$

註：判別器完整損失包含梯度懲罰項  $\mathcal{L}_D = \mathbb{E}[D(G(z, I_s))] - \mathbb{E}[D(I_t)] + \lambda_{gp} \mathbb{E}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$  [4][5]

## 一、訓練及生成結果

由圖 6 之損失曲線可見，訓練過程 L1 損失 (L1 Loss) 迅速下降趨近至 0，判別器損失 (Discriminator Loss) 急速下降後回升並穩定，符合 WGAN-GP 理論趨勢。而相較傳統 GAN 易出現模式崩潰、生成圖片偏灰及筆畫細節錯誤的情況 (圖 5)，本研究使用的 WGAN-GP 架構獲得了優良且穩定的效果。(展示圖像皆為測試集之結果)




圖 5：GAN (上) 與 WGAN-GP (下) 架構模型生成效果對比




圖 6：在 WGAN-GP 架構下訓練之損失圖形




圖 8：不同縮放程度對生成結果之影響




圖 9：不同平移程度對生成結果之影響




圖 10：不同旋轉程度對生成結果之影響




圖 11：不同遮罩機率對生成結果之影響




圖 7：本研究之 WGAN-GP 架構模型在各字體的生成效果

## 二、同步變換增強對泛化能力以及生成效果的影響

適當的縮放比例具正面影響，但過大將造成結構錯誤，過小則使較細的筆劃被忽略 (圖 8)。平移變換與前者類似，在適當的設定下是影響模型泛化能力的關鍵 (圖 9)。旋轉變換則因破壞了字型之間的筆畫偏移關係及橫豎向筆畫粗細連結，效果是不顯著甚至負面的，(圖 10)。隨機遮罩增強則在所有測試中皆導致生成品質下降 (圖 11)。

## 三、瓶頸層尺寸對生成效果之影響

1×1 的瓶頸層導致模型失去對結構的理解，出現字符混淆的現象。綜合視覺評估以及量化評分 (圖 12、表 1)，得出 4×4 及 8×8 的瓶頸層具有最好的表現。為客觀說明此現象，本研究進行以下測試：

1. 遮蔽測試：訓練完畢後，遮蔽瓶頸層部分區塊並嘗試生成字體。證實其確實攜帶位置資訊，但不同尺寸的瓶頸層所攜帶的資訊並無法看出明顯差異 (圖 13)。
2. 特徵降維分群測試：將瓶頸層特徵展平，透過 t-SNE 降維處理後觀察不同字符的分佈。[13]
3. Linear Probe 測試：凍結編碼器參數，並在瓶頸層後附加一線性回歸層預測字符的邊框座標，透過其預測能力評估模型保留的空間資訊差異 (圖 14)。




圖 12：不同瓶頸層尺寸 n=1,2,4,8,16 (依序) 對字體 A 的生成效果影響 (第一列為目標)

表 1：不同瓶頸層下字體 B、C 於測試集之 SSIM、LPIPS、FID 評分

| Bottleneck size (n×n) | Font B SSIM ↑ | Font B LPIPS ↓ | Font B FID ↓   | Font C SSIM ↑ | Font C LPIPS ↓ | Font C FID ↓   |
|-----------------------|---------------|----------------|----------------|---------------|----------------|----------------|
| 1×1                   | 0.5965        | 0.2430         | 111.0820       | 0.6147        | 0.2544         | 111.4700       |
| 2×2                   | 0.7178        | 0.1311         | 69.3894        | 0.7496        | 0.1196         | 72.1536        |
| 4×4                   | <b>0.7626</b> | <b>0.1020</b>  | <b>40.1179</b> | <b>0.8013</b> | 0.0790         | <b>25.5683</b> |
| 8×8                   | <b>0.7575</b> | <b>0.0994</b>  | <b>40.2646</b> | <b>0.8032</b> | <b>0.0768</b>  | <b>23.0104</b> |
| 16×16                 | 0.7512        | 0.1032         | 54.7411        | 0.7921        | <b>0.0749</b>  | 35.0887        |

n=2, Mask: Top-Left/Bottom-Right/Center n=8, Mask: Top-Left/Bottom-Right/Center



圖 13：字體 A 瓶頸層遮蔽測試 (n=2, n=8)




圖 14：Linear Probe 測試示意圖




圖 15：字體 A 下不同尺寸瓶頸層的 t-SNE 測試結果




圖 16：字體 A 下不同尺寸瓶頸層的 Linear Probe 測試結果



1. 過小的瓶頸層 ( $1 \times 1$ ) 造成資訊過度壓縮：  
t-SNE 測驗分群失敗，代表瓶頸層中多數字符無明顯特徵區別（如圖 15 左側）說明此時「瓶頸層的資訊過度壓縮」是導致生成效果不理想的原因。
2. 過大的瓶頸層 ( $n > 8$ ) 造成雜訊過多、無法精煉：  
分群測試出現大量誤將同字符分至不同群的現象（如圖 15 右側），代表瓶頸層出現過多的雜訊。Linear Probe 測試則出現過嚴重擬合現象，（如圖 16 右側）說明其無法將保留的位置資訊精煉成利於泛化的特徵，使生成效果不佳。
3. 兩項測試成績與實際生成效果的部分矛盾：

由於 Linear Probe 測試和 t-SNE 分群皆僅需簡略的資訊來區分特徵， $2 \times 2$  的瓶頸層已能勝任。不過當生成精細字體時， $4 \times 4$  及  $8 \times 8$  的瓶頸層保留的高頻資訊始得以在深層解碼器的還原下，協助生成字體而非成為干擾。



圖 17：模型層數對生成效果之影響

透過模型層數調整，排除參數量的影響（圖 21）

## 四、最佳化損失函數權重配置

已知  $1 \times 1$  的瓶頸層容易造成模式崩潰，此時設定較高的 L1 損失權重可改善此情況，但其結構及筆畫細節仍不穩定，更出現嚴重的模糊現象。不同的是，當瓶頸層較大時 ( $n \geq 4$ )，可完全移除 L1 損失，避免其容易造成的模糊現象（圖 23）。這是因為 WGAN-GP 使用的 Wasserstein 距離能在結構誤差較大時持續提供有效的梯度，取代 L1 損失引導模型修正幾何結構，生成清晰且準確的圖像。相較前人研究 [5][6][8][11] 須依賴 L1 損失來約束結構，是有價值的發現。

表 2：本研究之模型於其中二字體與其他研究之模型在 SSIM、LPIPS、FID 之評分

| 模型/測試指標              | SSIM ↑ | LPIPS ↓ | FID ↓   | 訓練字符數           |
|----------------------|--------|---------|---------|-----------------|
| 本研究模型訓練於字體 D         | 0.5617 | 0.1321  | 22.2059 | 230             |
| 本研究模型訓練於字體 E         | 0.6337 | 0.1105  | 33.8887 | 230             |
| DGFont++ [8] (2022)  | 0.8125 | 0.1234  | 34.54   | 800 / per Font  |
| RAC-Font [11] (2024) | 0.7051 | 0.1119  | 34.34   | 3300 / per Font |




圖 18、19：n=1、n=4 時  $\lambda_{L1}$  對生成效果之影響

訓練集代表字




圖 20：將本研究架構應用於中文字體生成之效果成效

## 五、評估跨語言字體生成之可行性

以 230 個常見部首與基本字符作為訓練集。由於漢字部件高度複用，同步變換增強發揮極佳效果。訓練集字符（如「星」）能完全還原目標字體風格；含類似部件的測試集字符整體結構正確，且保留目標字體的筆觸特徵（如圖綠框處）。然而如「愛、極」等筆畫密集的字符，因訓練集從未出現類似結構，加上  $64 \times 64$  的解析度限制，出現嚴重筆畫沾黏與模糊。（圖 20）

由表 2 可見，在訓練字符遠少於其餘模型的情況下，本研究在 FID 與 LPIPS 指標達到與前沿模型持平或更優的成績，但 SSIM 仍有明顯差距，且不同字體的表現差異較大，亦為後續改善的方向之一。

# 伍、結論

### 一、WGAN-GP 架構的高穩定性：

本研驗證了 WGAN-GP 在字體生成任務的高穩定性。有效解決傳統 GAN 易發生的梯度消失、模式崩潰及圖片模糊等問題，並發現此架構的模型得在無 L1 損失輔助下自我修正結構。

### 二、同步變換增強的邊界效應：

同步變換增強再次被證實能有效提升模型的泛化能力。然而過度的變換會導致結構裁切，形成誤導性的無效數據。此外，隨機遮罩與旋轉變換對於字體生成則帶來偏負面的影響。

### 三、瓶頸層空間維度是結構完整性的關鍵：

透過 t-SNE 與 Linear Probe 實驗說明  $n=1$  的過度壓縮會導致空間資訊的流失，造成結構崩潰或字符混淆。 $n > 8$  時則因為保留過多雜訊效果不佳，綜合量化結果得出  $n=4$  與  $n=8$  為最佳的設定。

### 四、基於 WGAN-GP 時，L1 損失依賴性方面之突破

在此架構下，當瓶頸層保留足夠的空間資訊 ( $n \geq 4$ ) 時，模型可擺脫對傳統 L1 像素損失的依賴。此突破源自於架構中 Wasserstein 距離的特性，其能在生成結構錯誤時持續提供有效梯度，引導幾何結構修正。使我們得以生成結構準確同時保有銳利筆畫細節的圖像。此發現更為輕量化模型與圖像模糊的改善提供了一條簡潔有效的優化路徑。

### 五、跨語言生成的潛力與限制：

將架構應用至中文字體生成亦展現了高度可行性。在此架構下，僅使用 230 個字符訓練，模型即能推論出從未見過的漢字，更在部分量化評估指標取得優於前沿模型的成果。唯受限於  $64 \times 64$  的解析度，結構複雜的字符仍存在筆畫沾黏與模糊等限制。

# 陸、參考文獻

- [1] Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. *Advances in neural information processing systems*, 27.
- [2] Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*.
- [3] Arjovsky, M., Chintala, S., & Bottou, L. (2017). Wasserstein generative adversarial networks. In *International conference on machine learning* (pp. 214-223). PMLR.
- [4] Gulrajani, I., Ahmed, F., Arjovsky, M., Dumoulin, V., & Courville, A. C. (2017). Improved training of wasserstein gans. *Advances in neural information processing systems*, 30.
- [5] Isola, P., Zhu, J. Y., Zhou, T., & Efros, A. A. (2017). Image-to-image translation with conditional adversarial networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 1125-1134).
- [6] Tian, Y. (2017). Z2ai: Master Chinese Calligraphy with Conditional Adversarial Networks. Github. <https://github.com/kaonashi-tyc/z2ai>
- [7] Wen, C., Pan, Y., Chang, J., Zhang, Y., Chen, S., Wang, Y., ... & Tian, Q. (2021). Handwritten Chinese font generation with collaborative stroke refinement. In *Proceedings of the IEEE/CVF winter conference on applications of computer vision* (pp. 3882-3891).
- [8] Chen, X., Xie, Y., Sun, L., & Lu, Y. (2022). Dgfont++: Robust deformable generative networks for unsupervised font generation. *arXiv preprint arXiv:2212.14742*.
- [9] 邱泓翔 (2018)。運用GAN實現字體風格轉換。中華民國第 58 屆中小學科學展覽會。高級中等學校組電腦與資訊學科 052511。
- [10] Pathak, D., Krahenbuhl, P., Donahue, J., Darrell, T., & Efros, A. A. (2016). Context encoders: Feature learning by inpainting. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 2536-2544).
- [11] Lee, J. S., & Choi, H. C. (2024). One-shot font generation via local style self-supervision using Region-Aware Contrastive Loss. *Journal of King Saud University-Computer and Information Sciences*, 36(4), 102028.
- [12] Zeng, J., Chen, Q., Liu, Y., Wang, M., & Yao, Y. (2021, May). Strokegan: Reducing mode collapse in chinese font generation via stroke encoding. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 35, No. 4, pp. 3270-3277).
- [13] Goldfeld, Z., & Polyanskiy, Y. (2020). The information bottleneck problem and its applications in machine learning. *IEEE Journal on Selected Areas in Information Theory*, 1(1), 19-38.